Estratégia de escalabilidade

O trabalho pesado por trás

Tudo o que dá trabalho, como varrer e-mails, fazer OCR e analisar documentos, acontece em segundo plano e de forma assíncrona, e o usuário vê quando um documento ainda está em processamento. Cada solicitação é tratada de forma independente, então o grande volume de um usuário não atrapalha os outros. Arquivos inválidos ou acima de 20mb são rejeitados antes do processamento, só os dados estruturados são guardados depois e o plano limita quantos e-mails cada pessoa integra. Se um e-mail ou PDF der erro, o sistema registra e segue com os demais.

Sincronização e proteção dos dados

Quando muitos aparelhos sincronizam, as operações feitas sem conexão ficam pendentes no aparelho e são enviadas uma única vez, e as alterações chegam aos outros dispositivos vinculados depois da sincronização. Quem troca de celular recupera garantias, alertas e histórico em até dois minutos, em condições normais, para proteger as informações, o sistema faz backups, preferencialmente diários, e registra em auditoria as ações relevantes.

Crescer sem perder desempenho

Para crescer sem perder desempenho, a arquitetura da API e do banco de dados deve suportar mais usuários e mais requisições de OCR sem degradação, organizada em módulos independentes que podem ser atualizados sem interromper o serviço. Como é difícil de medir, sugerimos escrever que, mesmo com muita gente ao mesmo tempo, a tela principal continua em até três segundos e a sincronização inicial em até dois minutos.

Como a parte técnica sustenta isso

Por baixo, a equipe técnica pode sustentar isso com uma API sem estado atrás de um balanceador de carga, que liga mais instâncias conforme a demanda, e com um pool de conexões para o banco não esgotar. O dashboard é lido de um resumo pronto de cada usuário, e os relatórios usam réplicas de leitura. OCR, IA e leitura de e-mails vão para uma fila, com divisão justa entre os usuários nos picos, como o horário dos alertas e o fim do mês, espalhamos os envios com atraso aleatório e limitamos a leitura de e-mails antigos por usuário. Se o Gmail ou o Outlook falhar, usamos tempo máximo de espera, novas tentativas e um disjuntor, e acompanhamos o tempo de resposta (p95), os erros e a fila com testes de carga.

Duas pessoas no mesmo dado

O caso de uso simultâneo mais real do sistema é a mesma conta aberta em dois aparelhos ou um bem compartilhado entre parentes, e o projeto ainda não diz o que acontece quando os dois alteram o mesmo registro. O sistema salva apenas a primeira alteração e avisa o segundo usuário, com mensagem clara, que o registro foi atualizado, pedindo que recarregue antes de tentar de novo, sem sobrescrever nada sem aviso e sem duplicar operações reenviadas. Também vale deixar claro que um erro da IA encerra só aquele documento.

Conclusão

Mesmo com muitos usuários ao mesmo tempo, a tela principal do sistema carrega as informações e os alertas em até três segundos, porque os processamentos pesados não bloqueiam o carregamento inicial. Se a internet falhar, o app continua mostrando o que já foi sincronizado e avisa quando uma função depende do servidor, o sistema mantém a resposta rápida mostrando primeiro o que o usuário precisa ver e deixando o trabalho pesado para o segundo plano.